

Implementasi Natural Language Processing (NLP) untuk Analisis Sentimen Movie Reviews Menggunakan BERT

Jason Cahyadhie Soh

Informatika, Fakultas Sains, Komputer dan Matematika, Matana University, Matana
University Tower, Jl. CBD Barat Kav. 1, Gading Serpong, Tangerang, Indonesia

PENDAHULUAN

A. Latar Belakang

Perkembangan internet dan media digital menyebabkan jumlah data teks yang dihasilkan pengguna semakin meningkat, salah satunya berupa ulasan film atau movie reviews pada berbagai platform online. Ulasan tersebut berisi opini, kritik, dan penilaian pengguna terhadap sebuah film sehingga dapat menjadi sumber informasi penting bagi masyarakat maupun industri hiburan. Namun, banyaknya jumlah review membuat proses analisis secara manual menjadi kurang efektif dan memerlukan waktu yang lama. Oleh karena itu, diperlukan suatu sistem otomatis yang mampu mengolah dan menganalisis sentimen dari data teks secara cepat dan akurat.

Natural Language Processing merupakan salah satu cabang kecerdasan buatan yang digunakan untuk memahami dan mengolah bahasa manusia oleh komputer. Salah satu penerapan NLP yang banyak digunakan adalah analisis sentimen, yaitu proses mengklasifikasikan opini pada teks ke dalam kategori positif, negatif, atau netral. Dalam penelitian sebelumnya, berbagai metode seperti Naive Bayes, Support Vector Machine (SVM), dan Convolutional Neural Network (CNN) telah digunakan untuk analisis sentimen. Namun, beberapa metode tersebut masih memiliki keterbatasan dalam memahami konteks kata dan hubungan antar kalimat secara mendalam.

Seiring perkembangan teknologi deep learning, muncul model berbasis Transformer yaitu BERT (Bidirectional Encoder Representations from Transformers) yang memiliki kemampuan memahami konteks bahasa secara dua arah sehingga mampu menghasilkan representasi teks yang lebih baik. BERT dinilai efektif dalam tugas analisis sentimen karena dapat memahami makna kalimat dengan lebih akurat, termasuk pada teks ulasan film yang memiliki variasi bahasa dan opini yang kompleks. Berdasarkan hal tersebut, penelitian ini bertujuan untuk mengimplementasikan NLP menggunakan model BERT dalam analisis sentimen movie reviews guna memperoleh hasil klasifikasi yang lebih optimal dan akurat.

B. Rumusan Masalah

1. Bagaimana mengimplementasikan Natural Language Processing untuk analisis sentimen pada data movie reviews?
2. Bagaimana menerapkan model BERT dalam proses klasifikasi sentimen movie reviews?
3. Bagaimana tingkat performa model BERT dalam mengklasifikasikan sentimen positif dan negatif pada movie reviews berdasarkan nilai accuracy, precision, recall, dan F1-score?

C. Batasan Masalah

- Penelitian ini hanya berfokus pada analisis sentimen teks movie reviews menggunakan pendekatan Natural Language Processing.
- Data yang digunakan berupa ulasan film berbentuk teks dan tidak mencakup data gambar, audio, maupun video.
- Klasifikasi sentimen dibatasi pada dua kategori, yaitu positif dan negatif.
- Model yang digunakan dalam penelitian ini adalah BERT sebagai metode utama klasifikasi sentimen.
- Tahapan penelitian meliputi preprocessing data, training model, pengujian model, dan evaluasi performa menggunakan accuracy, precision, recall, dan F1-score.
- Implementasi sistem dilakukan menggunakan bahasa pemrograman Python dan framework pendukung NLP/deep learning.

D. Tujuan

- Mengimplementasikan Natural Language Processing untuk melakukan analisis sentimen pada data movie reviews.
- Menerapkan model BERT dalam proses klasifikasi sentimen movie reviews.
- Menganalisis performa model BERT dalam mengklasifikasikan sentimen positif dan negatif berdasarkan nilai accuracy, precision, recall, dan F1-score.
- Menghasilkan model analisis sentimen yang mampu memberikan hasil klasifikasi secara optimal dan akurat terhadap movie reviews.

METODOLOGI

A. Metode penelitian

Penelitian ini menggunakan pendekatan eksperimen dengan metode kuantitatif untuk mengembangkan dan mengevaluasi model klasifikasi sentimen pada movie reviews. Jenis penelitian ini termasuk dalam kategori applied research yang bertujuan menerapkan Natural Language Processing menggunakan model BERT dalam menyelesaikan permasalahan analisis sentimen teks. Pendekatan penelitian mengikuti tahapan umum deep learning dan NLP yang meliputi data collection, preprocessing, tokenization, model training, evaluation, dan prediction.

Tahapan penelitian dilakukan secara sistematis melalui pipeline terstruktur agar proses pengembangan model berjalan secara terorganisir dan mudah direproduksi. Tahap preprocessing dilakukan untuk membersihkan data teks sebelum diproses oleh model BERT. Selanjutnya dilakukan tokenization dan encoding menggunakan tokenizer BERT untuk mengubah teks menjadi representasi numerik. Model kemudian dilatih menggunakan data training dan dievaluasi menggunakan data testing dengan parameter accuracy, precision, recall, dan F1-score untuk mengetahui performa klasifikasi sentimen.

B. Sumber dataset

Data yang digunakan adalah IMDb Dataset of 50K Movie Reviews yang diperoleh dari Kaggle. Dataset ini merupakan salah satu benchmark standar untuk tugas sentiment analysis klasifikasi biner.

Karakteristik	Deskripsi
Jumlah sampel	50.000 review film
Distribusi label	25.000 Positive, 25.000 Negative (balanced)
Bahasa	Inggris
Format	CSV dengan 2 kolom: review dan sentiment
Panjang teks	Variatif (rata-rata 200-500 karakter)

C. Preprocessing Data

Penelitian ini dilakukan melalui beberapa tahapan secara sistematis untuk membangun model analisis sentimen movie reviews menggunakan Natural Language Processing dan BERT. Tahapan penelitian yang dilakukan adalah sebagai berikut:

1. Pengumpulan Dataset

Tahap awal penelitian dilakukan dengan mengumpulkan dataset berupa IMDb Dataset of 50K Movie Reviews yang diperoleh dari platform Kaggle. Dataset terdiri dari data review film dengan label sentimen positif dan negatif.

2. Preprocessing Data

Pada tahap ini dilakukan pembersihan dan persiapan data teks agar dapat diproses oleh model BERT. Tahapan preprocessing meliputi:

- Case folding
- Remove punctuation
- Remove HTML tags
- Cleaning text
- Tokenization
- Padding dan truncation

3. Pembagian Dataset

Dataset yang telah diproses kemudian dibagi menjadi data training dan data testing. Pembagian data dilakukan untuk melatih model dan menguji performa model dalam klasifikasi sentimen.

4. Tokenization dan Encoding

Teks review diubah menjadi representasi numerik menggunakan tokenizer dari model BERT. Proses ini menghasilkan token ID dan attention mask yang digunakan sebagai input model.

5. Training Model BERT

Model BERT dilatih menggunakan data training untuk mempelajari pola sentimen pada movie reviews. Proses training dilakukan dengan menentukan parameter seperti epoch, batch size, optimizer, dan learning rate.

6. Evaluasi Model

Model yang telah dilatih kemudian diuji menggunakan data testing. Evaluasi dilakukan menggunakan beberapa metrik performa seperti accuracy, precision, recall, dan F1-score untuk mengetahui tingkat akurasi klasifikasi sentimen.

7. Analisis Hasil

Tahap terakhir dilakukan analisis terhadap hasil pengujian model untuk mengetahui kemampuan BERT dalam mengklasifikasikan sentimen movie reviews serta membandingkan hasil performa yang diperoleh.

D. Arsitektur / Model BERT

Model yang digunakan dalam penelitian ini adalah BERT (Bidirectional Encoder Representations from Transformers), yaitu model deep learning berbasis arsitektur Transformer yang dikembangkan oleh Google untuk tugas Natural Language Processing. BERT memiliki kemampuan memahami konteks kata secara dua arah (bidirectional) sehingga mampu menghasilkan representasi bahasa yang lebih baik dibandingkan metode NLP tradisional maupun model sequential biasa.

Pada penelitian ini digunakan model BERT pre-trained yang telah dilatih menggunakan corpus teks dalam jumlah besar. Proses implementasi dilakukan dengan metode fine-tuning, yaitu menambahkan layer klasifikasi pada bagian akhir model BERT untuk melakukan klasifikasi sentimen movie reviews ke dalam kategori positif dan negatif. Teks input terlebih dahulu diproses menggunakan BERT tokenizer untuk menghasilkan token ID, attention mask, dan sequence embedding sebelum masuk ke dalam model.

Arsitektur BERT terdiri dari beberapa komponen utama, yaitu embedding layer, encoder Transformer, self-attention mechanism, dan classification layer. Embedding layer berfungsi mengubah teks menjadi representasi vektor, sedangkan encoder Transformer digunakan untuk memahami hubungan konteks antar kata dalam kalimat. Self-attention mechanism memungkinkan model mempelajari keterkaitan setiap kata terhadap kata lainnya dalam suatu kalimat sehingga pemahaman konteks menjadi lebih optimal. Output dari encoder kemudian diteruskan ke classification layer untuk menentukan hasil klasifikasi sentimen.

Dalam proses pelatihan, model BERT menggunakan parameter seperti epoch, batch size, optimizer AdamW, dan learning rate untuk mengoptimalkan performa model. Hasil akhir model dievaluasi menggunakan accuracy, precision, recall, dan F1-score untuk mengetahui kemampuan model dalam melakukan klasifikasi sentimen secara akurat.

E. Tools dan Library

- a. Python 3.8+
- b. TensorFlow / Keras (model building & training)

- c. NLTK (text preprocessing)
- d. Scikit-learn (metrics & LabelEncoder)
- e. Pandas (data manipulation)
- f. NumPy (array operations)
- g. Selenium (web automation)
- h. BeautifulSoup4 (HTML parsing)
- i. Matplotlib (training visualization)
- j. Seaborn (confusion matrix)
- k. Streamlit (web deployment)

F. Diagram Alur Penelitian



HASIL DAN PEMBAHASAN

KESIMPULAN

DAFTAR PUSTAKA